Instituto Politécnico Nacional

Escuela Superior de Cómputo

Analítica Avanzada

Proyecto: Entregable de la Unidad I

Contaminación del aire en la Zona Metropolitana del Valle de México

Integrantes

- Sayuri Herrera Moreno
- Mauricio Antonio Rodas Cortes
- Francisco Pineda Hernández

1 de octubre de 2026

Resumen

Estudiamos la contaminación del aire en la Zona Metropolitana del Valle de México (ZMVM) con diez años de mediciones oficiales (2015 a 2024), los datos del Censo 2020 y estimaciones por satélite. Con ellos armamos un dataset de 3,653 días con el clima y la contaminación de cada día, y otro de 5,085 localidades con la población que vive en cada lugar.

Lo más importante que encontramos: el ozono rebasa la norma de salud en 2 de cada 3 días y no ha mejorado en diez años; depende sobre todo del calor (con más de 26 °C se rebasa la norma en 92% de los días); ni siquiera bajó cuando la ciudad se detuvo por la pandemia; y 4.45 millones de personas viven en las zonas donde más se rebasa. Como el calor y el viento se pueden pronosticar, proponemos usar estos datos para anticipar los días malos y avisar primero a quienes más lo necesitan.

1. Problemática a analizar

En la Zona Metropolitana del Valle de México viven más de 20 millones de personas y el aire rebasa con frecuencia los límites que protegen la salud. Los dos contaminantes que más preocupan son:

- Ozono (O3). No sale directamente de los escapes: se forma en el aire cuando los gases de los autos y la industria reciben luz del sol. Irrita las vías respiratorias.
- Partículas finas (PM2.5). Humo y polvo tan fino que entra hasta los pulmones.

Lo que nos llamó la atención es que la contaminación cambia mucho de un día a otro, aunque la ciudad funcione casi igual todos los días (los mismos autos, las mismas fábricas). Eso sugiere que el clima del día tiene mucho que ver.

Las preguntas del proyecto son:

1. ¿Qué tanto se relacionan el clima y el calendario con la contaminación de cada día?
2. ¿Cuánta gente, y en especial niños y adultos mayores, vive en las zonas donde más veces se rebasa la norma?

Responderlas sirve para algo concreto: si los días malos se parecen entre sí, se pueden anticipar y avisar a tiempo.

2. Variables de entrada propuestas

Son los datos que conocemos de un día (o de una localidad) y que usaremos como información inicial para explicar la contaminación.

Tabla 1. Variables de entrada del día

Grupo	Variable	Por qué podría influir
Clima	Temperatura máxima	Con calor y sol se forma más ozono
Clima	Diferencia entre la temperatura máxima y la mínima	Señala días despejados y secos, en los que el aire se estanca
Clima	Humedad	Los días húmedos o lluviosos limpian el aire
Clima	Velocidad del viento (todo el día y en la madrugada)	El viento se lleva la contaminación; sin viento se acumula
Clima	Dirección del viento	Indica de dónde viene el aire
Calendario	Fin de semana y día festivo	Cambia el tráfico; en las fiestas hay pirotecnia
Calendario	Época del año	La contaminación tiene temporadas
Calendario	Confinamiento de 2020	Hubo muchos menos autos en la calle
Día anterior	PM2.5 y ozono de ayer	Los días malos suelen venir seguidos

Tabla 2. Variables de entrada de cada localidad

Variable	Fuente
Población total, niños de 0 a 14 años y adultos de 65 o más	Censo 2020
Personas sin servicio médico	Censo 2020
Años de escuela promedio	Censo 2020
PM2.5 y NO2 (gas de los escapes) estimados desde el espacio	Satélite 2020

3. Posibles variables objetivo

Son los resultados que queremos analizar y, más adelante, predecir.

Tabla 3. Variables objetivo

Variable	Qué mide	Tipo
Ozono máximo del día (objetivo principal)	El valor más alto de ozono medido ese día	Número
PM2.5 promedio del día	Promedio de partículas finas en las 24 horas	Número
¿Se rebasó la norma de ozono?	Si el ozono pasó de 90 ppb en alguna estación	Sí / No
¿Se rebasó la norma de PM2.5?	Si el PM2.5 pasó de 41 µg/m^3 en alguna estación	Sí / No
Días al año sobre la norma	Cuántos días al año se rebasa la norma de ozono en la estación más cercana a cada localidad	Número

Elegimos el ozono como objetivo principal porque es el contaminante que más veces rebasa la norma. Los límites son los de las Normas Oficiales Mexicanas de salud (NOM-020 para ozono y NOM-025 para partículas).

4. Fuentes de datos exploradas

Estos son los lugares que revisamos para encontrar datos y lo que decidimos con cada uno.

Tabla 4. Fuentes revisadas

Fuente	Qué tiene	Decisión
Sistema de Monitoreo Atmosférico de la CDMX (aire.cdmx.gob.mx)	Contaminantes y clima medidos cada hora en las estaciones, 2015-2024	Se usa. Es la fuente principal: mediciones directas y día por día
Censo de Población y Vivienda 2020, INEGI	Población de cada localidad de la CDMX y el Estado de México	Se usa. Dice quién vive en cada lugar
Satélite 2020 (grupo ACAG, Universidad de Washington en San Luis)	PM2.5 y NO2 estimados desde el espacio	Se usa, después de comparar con las estaciones
Promedios por localidad de la red de monitoreo	Promedio de contaminación de 494 localidades de la CDMX	Solo como referencia
Egresos hospitalarios, Secretaría de Salud	Hospitalizaciones por municipio	No se usa. Reflejaba dónde hay hospitales, no el efecto del aire
Inventario de emisiones 2020, SEDEMA	Emisiones de todo el año por tipo de fuente	No se usa. Es un número por año; no muestra cambios diarios

5. Datos seleccionados

Nos quedamos con tres conjuntos de datos y los organizamos en dos tablas.

Tabla 5. Datos elegidos

Datos	Periodo	Para qué
Monitoreo atmosférico: 20 archivos con datos por hora (casi 25 millones de registros)	2015-2024	Dataset diario: un renglón por día. Es el dataset final de la entrega
Censo 2020 por localidad	2020	Dataset por localidad: quién vive dónde
Satélite de PM2.5 y NO2	2020	Dataset por localidad: contaminación

		donde no hay estación

El monitoreo atmosférico es la única fuente que cambia día con día, que es justo lo que queremos estudiar. El censo y el satélite se conservan porque las estaciones están casi todas en el centro de la ciudad y no dicen quién respira ese aire. Las dos tablas se conectan por las estaciones de monitoreo: a cada localidad le asignamos su estación más cercana.

6. Construcción del dataset para exploración

6.1 Dataset diario (dataset final)

Los datos originales vienen por hora y por estación. Para poder analizarlos los convertimos en un renglón por día:

1. Descargar y leer los 20 archivos. En 2022 la fuente cambió la forma de escribir la fecha, así que el código deja los dos formatos iguales.
2. Limpiar. Se quitaron los valores imposibles (23 en diez años; por ejemplo, una humedad mayor a 100%).
3. Resumir cada día en cada estación: promedio y valor más alto. Un día solo cuenta si tiene al menos 18 de las 24 horas con dato.
4. Juntar las estaciones en un solo renglón por día: promedio entre estaciones para el PM2.5 y el clima, y el valor más alto de cualquier estación para el ozono.
5. Agregar el calendario (mes, día de la semana, festivos, temporada, confinamiento), la contaminación del día anterior y si ese día se rebasó la norma.
6. Quitar las columnas que no son importantes. La tabla llegó a tener 37 columnas; quitamos 12 que repetían información o que no usamos en el análisis.

Resultado: 3,653 días (del 1 de enero de 2015 al 31 de diciembre de 2024) y 25 columnas: la fecha, 4 variables objetivo y 20 columnas de entrada o de apoyo. No hay días repetidos ni días sin registro.

Tabla 6. Columnas que se quitaron del dataset final

Columnas eliminadas	Por qué se quitaron
Otras dos formas de medir el ozono y el PM2.5 de la estación más alta	Repiten lo que ya dicen las variables objetivo
PM10 y SO2	Son contaminantes que no son objetivo del proyecto
Número de estaciones con dato (2 columnas)	Solo eran un control al armar la tabla
Temperatura promedio, viento máximo y temporada	Repiten información de la temperatura máxima y mínima, del viento promedio y del mes
Viento y temperatura del día anterior	No se usan en el análisis

Un problema que encontramos en los datos. En 2024 la velocidad del viento aparece al doble que en todos los años anteriores (4.4 contra 2.1 m/s), en todas las estaciones y sin que la fuente avise de un cambio. Como no es creíble que el viento se haya duplicado de un año a otro, dejamos el viento de 2024 como dato faltante (10% de los días).

6.2 Dataset por localidad

Para cada estación calculamos cuántos días al año rebasa la norma. Después, a cada localidad del censo le asignamos su estación más cercana, pero solo si está a 5 km o menos; más lejos ya no la representa. Resultado: 5,085 localidades y 32 columnas. Las estaciones de ozono alcanzan a cubrir al 61% de la población.

7. Análisis estadístico básico del dataset final

Esta sección es el análisis exploratorio de datos (EDA): revisar los datos con tablas y gráficas para conocerlos antes de construir cualquier modelo. Seguimos los pasos habituales de un EDA y en cada uno decimos qué buscamos y qué obtuvimos.

7.1 Conocer el dataset y revisar su calidad

Qué buscamos: saber cuántos datos hay, de qué tipo son y si hay datos faltantes o repetidos.

Qué obtuvimos: cada renglón es un día; hay 3,653 días (diez años completos) y 25 columnas, todas numéricas salvo la fecha. No hay días repetidos ni días sin registro. Lo único que falta de forma importante es el viento de 2024 (366 días, 10% del total), que nosotros mismos quitamos por no ser confiable.

7.2 Estadística descriptiva

Qué buscamos: el valor típico de cada variable y qué tanto cambia.

Tabla 7. Resumen de las variables principales (3,653 días)

Variable	Promedio	Mediana	Mínimo	Máximo
Ozono máximo del día (ppb)	100.5	102.0	22.0	210.0
PM2.5 promedio del día (µg/m^3)	20.9	20.1	2.9	86.9
Temperatura máxima (°C)	23.2	23.2	10.2	32.0
Temperatura mínima (°C)	11.4	12.1	0.6	17.3
Humedad (%)	54.8	56.4	12.1	88.7
Viento (m/s)	2.1	2.0	1.2	6.3

- El ozono máximo de un día típico es de 100 ppb, arriba del límite de 90. Por eso en 66% de los días (2 de cada 3) alguna estación rebasa la norma de ozono.
- El PM2.5 rebasa la norma mexicana en 13% de los días, pero en 75% de los días está arriba de lo que recomienda la Organización Mundial de la Salud.
- El clima cambia menos que la contaminación: la temperatura máxima casi siempre está entre 21 y 25 °C y aun así el ozono va de 22 a 210 ppb.

7.3 Distribuciones

Qué buscamos: ver qué valores son los más comunes. Cada barra dice cuántos días tuvieron ese valor.

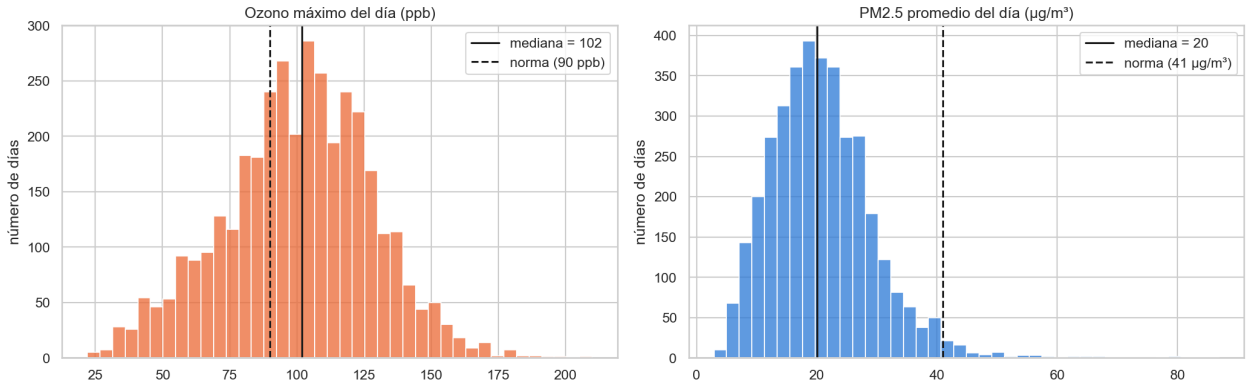


Figura 1. Qué valores de ozono y PM2.5 son los más comunes. La línea continua es la mediana y la punteada, la norma.

Qué obtuvimos: el ozono tiene forma de campana y su valor típico queda a la derecha de la norma: lo normal es rebasarla. El PM2.5 se concentra entre 15 y 26, con unos pocos días de valores muy altos. En el clima, la temperatura máxima se concentra entre 21 y 25 °C, la humedad es la que más cambia (de 12% a 89%) y el viento casi siempre está cerca de 2 m/s.

7.4 Valores atípicos

Qué buscamos: los días que se salen de lo común y saber si son errores o eventos reales.

Qué obtuvimos: los días muy alejados del resto son pocos (menos de 2% en los contaminantes) y no son errores, son eventos reales:

- Los días con más PM2.5 son Navidad y Año Nuevo (por la pirotecnia) y la semana del 11 al 16 de mayo de 2019, cuando hubo incendios forestales y contingencia ambiental.
- Los días con más ozono caen entre febrero y junio, con temperaturas de 26 a 30 °C.

Por eso se conservan en el dataset: son justo los días que interesa entender.

7.5 Comportamiento en el tiempo

Qué buscamos: saber si el aire ha mejorado en diez años y en qué meses, días y horas es peor.

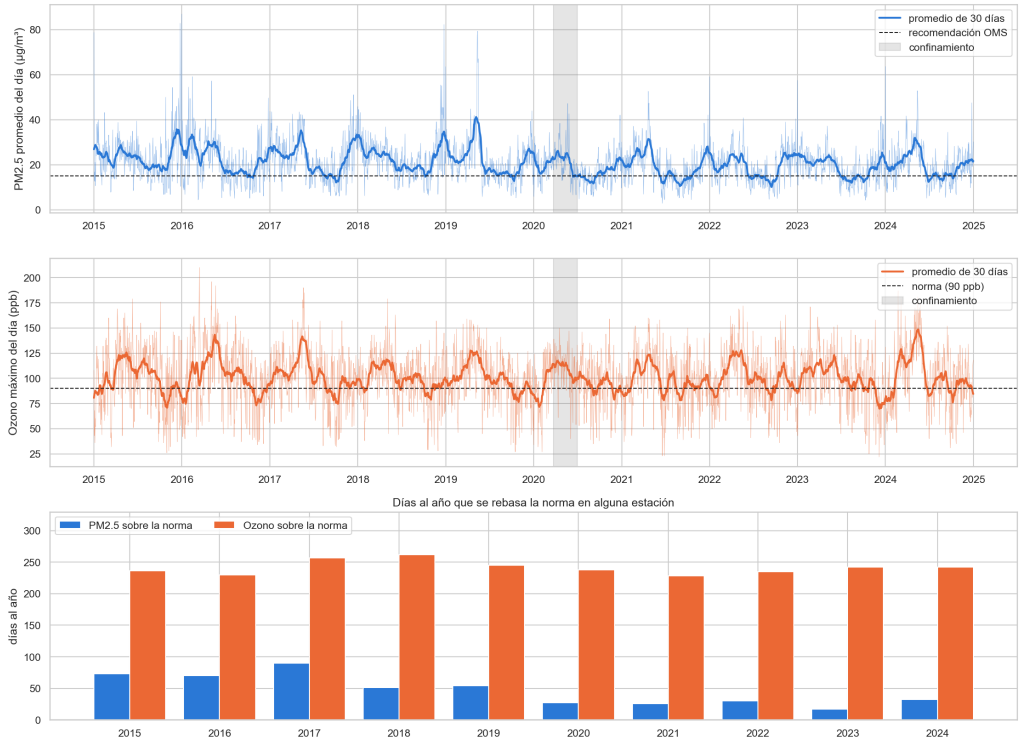


Figura 2. PM2.5 y ozono de cada día (2015-2024) y número de días al año que se rebasa la norma.

- El PM2.5 sí mejoró: desde 2020 los días sobre la norma pasaron de entre 50 y 90 al año a entre 17 y 32.
- El ozono no ha mejorado: todos los años se rebasa la norma entre 228 y 262 días.

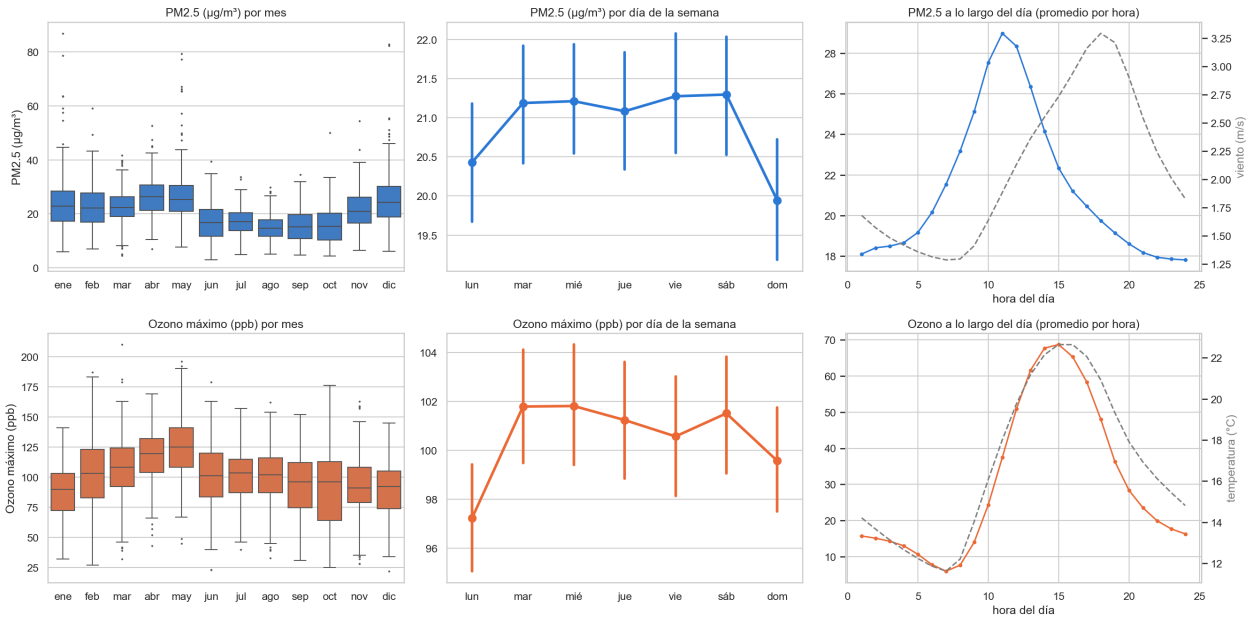


Figura 3. Contaminación por mes, por día de la semana y por hora del día.

- Por mes: el ozono es peor en abril y mayo (en mayo se rebasa la norma en 91% de los días). El PM2.5 es peor en diciembre y enero y baja mucho con las lluvias.
- Por día de la semana: casi no cambia; ni el domingo baja de forma clara el ozono.
- Por hora: el ozono sube y baja junto con la temperatura y llega a su máximo a las 3 de la tarde. El PM2.5 tiene su máximo a las 11 de la mañana.

¿Qué pasó cuando la ciudad se detuvo? Comparamos el confinamiento de 2020 (23 de marzo al 30 de junio) con las mismas fechas de 2015 a 2019.

Tabla 8. Confinamiento de 2020 contra los mismos meses de años anteriores

Contaminante	Promedio 2015-2019	Confinamiento 2020	Cambio
CO (gas de los escapes)	0.5	0.3	−50%
NO2 (gas de los escapes)	23.6	15.5	−34%
PM2.5	25.0	21.8	−13%
Ozono máximo	115.9	109.3	−6%

Con muchos menos autos, los gases de los escapes bajaron mucho, pero el ozono casi no bajó: se siguió rebasando la norma en 86% de los días (contra 82% en los años anteriores). Esos meses de 2020 fueron además 1 °C más calurosos.

7.6 Relación entre variables: el clima y la contaminación

Qué buscamos: cuáles variables de entrada se mueven junto con las variables objetivo. Medimos la relación con la correlación, un número entre −1 y 1: cerca de 1 significa que las dos cosas suben juntas; cerca de −1, que cuando una sube la otra baja; cerca de 0, que no tienen relación.

Tabla 9. Correlación de las variables de entrada con los dos objetivos

Variable de entrada	Con el ozono	Con el PM2.5
Temperatura máxima	0.62	0.23
Ozono de ayer	0.58	0.44
PM2.5 de ayer	0.37	0.72
Diferencia entre temperatura máxima y mínima	0.45	0.43
Humedad	−0.30	−0.35
Viento	−0.23	−0.40
Fin de semana	0.01	−0.02
Confinamiento	0.06	0.02

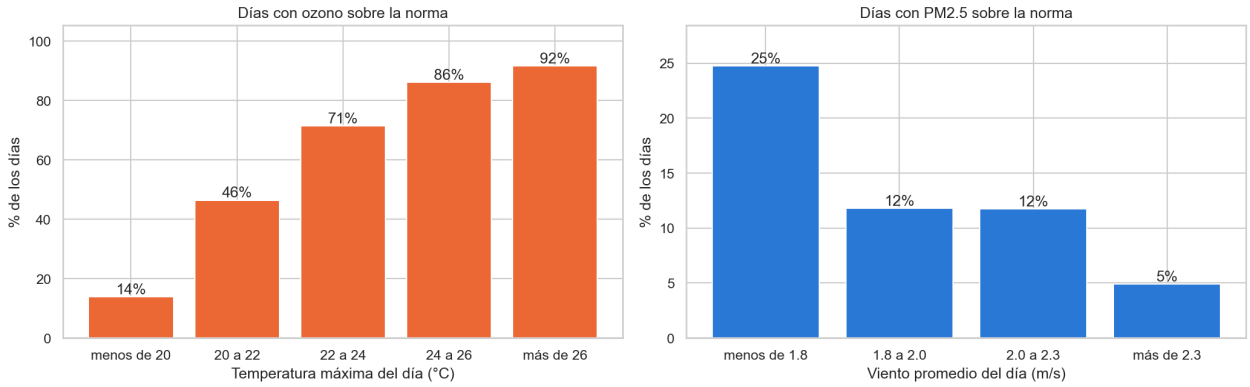


Figura 4. Porcentaje de días en que se rebasa la norma según la temperatura (ozono) y el viento (PM2.5).

- Temperatura y ozono: con menos de 20 °C se rebasa la norma en 14% de los días; con más de 26 °C, en 92%.
- Viento y PM2.5: con poco viento se rebasa la norma en 25% de los días; con viento fuerte, en 5%.
- Los días malos vienen en racha: si ayer se rebasó la norma de ozono, hoy se rebasa en 79% de los casos (contra 40% si ayer no).

7.7 ¿El satélite coincide con las estaciones?

El satélite cubre toda la zona, pero es una estimación. Antes de confiar en él lo comparamos con lo que midieron las estaciones en 2020.

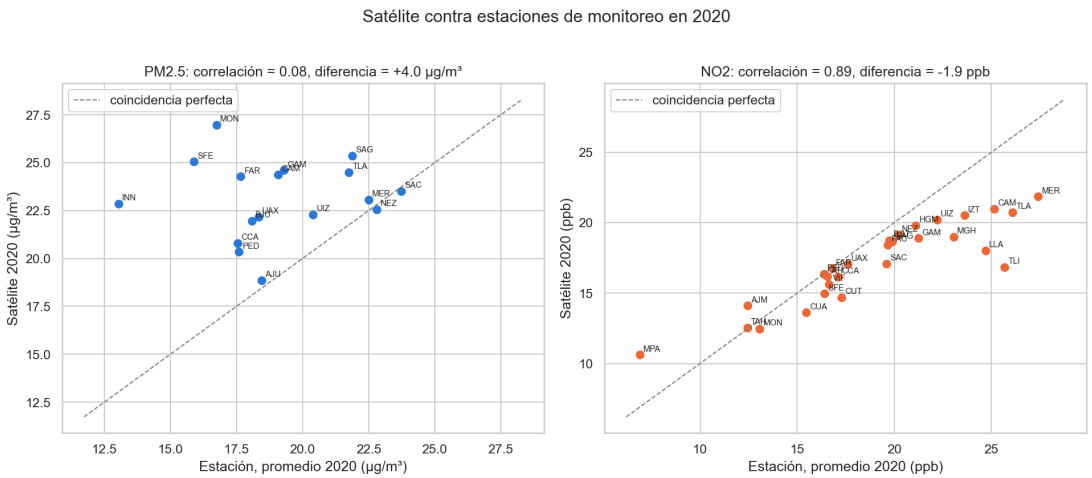


Figura 5. Satélite contra estaciones en 2020. Si coincidieran, los puntos caerían sobre la línea punteada.

- NO2: el satélite sí coincide con las estaciones (correlación de 0.89). Se puede usar donde no hay estación.
- PM2.5: el satélite no coincide (correlación de 0.08) y marca 4 µg/m^3 de más. Para PM2.5 nos quedamos con las estaciones.

7.8 ¿Quién respira el aire más contaminado?

Las estaciones donde más se rebasa la norma de ozono están en el sur y poniente de la ciudad (Pedregal, Ciudad Universitaria, Coyoacán, Ajusco), con más de 150 días al año. Contamos cuánta gente vive a 5 km o menos de una estación que rebasa la norma más de 120 días al año, es decir, uno de cada tres días.

Tabla 10. Población que vive cerca de las estaciones con más ozono

Grupo	Personas	Parte del grupo que vive en esas zonas
Población total	4,454,495	28%
Niños de 0 a 14 años	733,012	24%
Adultos de 65 años o más	534,121	33%
Personas sin servicio médico	1,148,590	25%

Los porcentajes se calculan sobre la población que tiene una estación a 5 km o menos (15.9 millones). En la CDMX casi toda la población (98%) tiene una estación cerca; en el Estado de México, solo 40%.

7.9 Resumen del EDA

Tabla 11. Qué obtuvimos en cada paso del EDA

Paso del EDA	Qué obtuvimos
Conocer el dataset	3,653 días (2015-2024) y 25 columnas, todas numéricas salvo la fecha
Calidad de los datos	Sin días repetidos ni días sin registro. Solo falta el viento de 2024 (10%)
Estadística descriptiva	El ozono típico (100 ppb) está arriba de la norma (90): se rebasa en 66% de los días. El PM2.5, en 13%
Distribuciones	El ozono tiene forma de campana; el PM2.5 tiene unos pocos días con valores muy altos
Valores atípicos	Menos de 2% de los días y son eventos reales (pirotecnia e incendios). Se conservan
Comportamiento en el tiempo	El PM2.5 bajó desde 2020; el ozono no. El ozono es peor en abril-mayo y a las 3 de la tarde
Relación entre variables	Ozono: temperatura (0.62) y ozono de ayer (0.58). PM2.5: PM2.5 de ayer (0.72) y viento (−0.40)
Dataset por localidad	El satélite sirve para NO2 pero no para PM2.5. 4.45 millones de personas viven donde más ozono hay

Conclusión del EDA: los datos están limpios y completos, y las variables de entrada que propusimos (sobre todo temperatura, viento y la contaminación del día anterior) sí se relacionan con las variables objetivo. El dataset está listo para la siguiente etapa.

8. Hallazgos: qué encontramos

1. El problema de fondo es el ozono, y no ha mejorado. Se rebasa la norma en 2 de cada 3 días, todos los años de 2015 a 2024. El PM2.5 sí bajó a partir de 2020.
2. El calor es la mejor pista del ozono. Con menos de 20 °C se rebasa la norma en 14% de los días; con más de 26 °C, en 92%. Por eso abril y mayo son los peores meses y las 3 de la tarde la peor hora.
3. El viento limpia las partículas. Con poco viento el PM2.5 rebasa la norma cinco veces más seguido que con viento fuerte. Sus peores días son Navidad, Año Nuevo y los incendios de mayo de 2019.
4. Los días malos vienen en racha. Si ayer se rebasó la norma de ozono, hay 79% de probabilidad de que hoy se repita.
5. Sacar autos de circulación no bastó para bajar el ozono. En el confinamiento de 2020 los gases de los escapes bajaron entre 34% y 50%, pero el ozono solo 6%. Tampoco baja en fin de semana. Fue lo que más nos sorprendió.

6. El ozono pega más en el sur y poniente de la ciudad, no en el norte industrial. Ahí viven 4.45 millones de personas, entre ellas 733 mil niños y 534 mil adultos mayores.
7. No todos los datos son igual de confiables. El satélite sirve para NO2 pero no para PM2.5, y el viento de 2024 viene mal en la fuente oficial. Si no se revisa, se llega a conclusiones equivocadas.

Límites de este avance

- Lo que vimos son relaciones, no pruebas de causa: que el ozono suba con el calor no significa que el calor sea lo único que lo provoca.
- Las estaciones solo cubren al 61% de la población; del resto no hay mediciones directas.
- El satélite es solo de 2020 y falta el viento de 2024.

Fuentes

- Secretaría del Medio Ambiente de la Ciudad de México. Sistema de Monitoreo Atmosférico (SIMAT): bases de datos horarias de contaminantes y meteorología, 2015-2024. https://aire.cdmx.gob.mx
- INEGI. Censo de Población y Vivienda 2020: principales resultados por localidad. https://www.inegi.org.mx/programas/ccpv/2020/
- Atmospheric Composition Analysis Group, Washington University in St. Louis. Estimaciones satelitales de PM2.5 y NO2, 2020. https://sites.wustl.edu/acag/
- Secretaría de Salud. NOM-020-SSA1-2021 (ozono) y NOM-025-SSA1-2021 (partículas). Diario Oficial de la Federación.
- Organización Mundial de la Salud (2021). Directrices mundiales de la OMS sobre la calidad del aire.